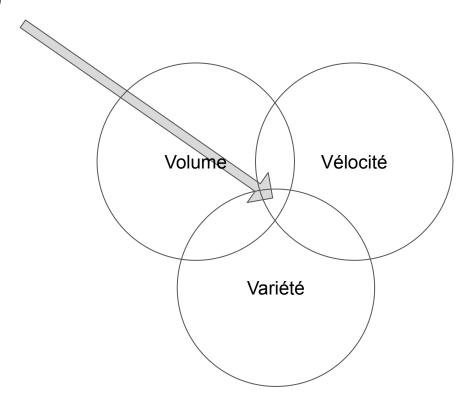
Introduction

Introduction

Nous générons de plus en plus de données:

- Transactions financières
- Événement d'équipement réseaux
- ▼ IOT
- Log serveur
- Click Stream (Navigation Web)
- ▼ E-mail et formulaire web
- Données issues des réseaux sociaux

Le problème



Le problème : Volume

- **▼** Finances
 - ∇ Presques 4 milliards d'actions échangées par jour à la bourse de New York
- Facebook
- **▼** Twitter
 - √ 400 000 tweets écrits par minute
- ▼ IoT
 - ▼ Tesla a capturé des informations issues de plus d'1 milliard de km

Le problème : Variété

- Donnée Structurée
 - ▼ BDD
- Donnée Non Structurée
 - ∇ Page Web

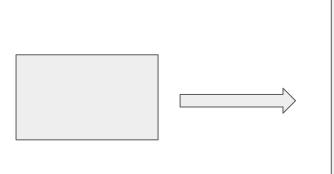
 - ∀ Vidéo

Le problème : Vélocité

- ▼ Fréquence de mise à jour
- Temps Réel

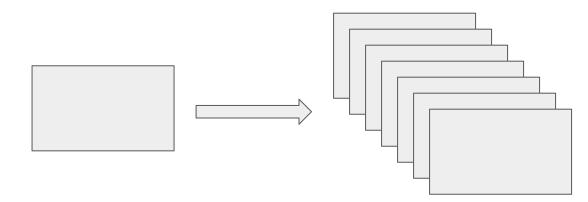
| Approche Vertical

- ▼ CPU plus rapide
- ▼ Plus de mémoire
- ▼ Programmation Simple
- ▼ Limité par le matériel
- Faible volume



| Approche Horizontal

- Gros volume
- Plusieurs machines
- **▼** Programmation complexe
 - ∇ Gestion des crashs
 - □ Distribution des calculs



l Problème de la donnée

- Traditionnellement centralisé
- ▼ Transfert de donnée pour les traitements
- ▼ Bande passante réseau limité

Le besoin

- ▼ Facilement scalable
- ▼ Tolérant à la panne
- ▼ Rentable (hardware peu coûteux)

Naissance de Hadoop

- ▼ GFS (2003)
- ▼ MapReduce (2004)
- ▼ Hadoop (2006)
 - → HDFS
 - ∀ Hadoop MapReduce



| Qu'est ce que Hadoop

- Plateforme de Stockage et de Calcul Distribué

 - □ permet de se concentrer sur les problèmes business et non infra
- Différent cas d'usage possible
 - ▼ Extract Transform Load
 - ▼ Business Intelligence
 - ∇ Stockage
 - ▼ Machine Learning
 - ∇ ...

| Hadoop est scalable

- ▼ ajout facile de noeud
- ▼ augmentation de ressource = augmentation de performance
- ▼ gestion des échecs
 - ∇ le système continue de fonctionner
 - ∇ la tâche est attribuée à un autre noeud
 - pas de perte de donnée car réplication

Hadoop écosystème

- riche
- open source
- **▼** grandissant
 - ∇ Spark (2014)
 - ▼ Kafka (2012)

L'écosystème Hadoop

HDFS - Hive - YARN - Oozie

HDFS

Hadoop Distributed File System

HDFS

- Comme un système de fichier classique
- ▼ distribué
- haute disponibilité
- résilience

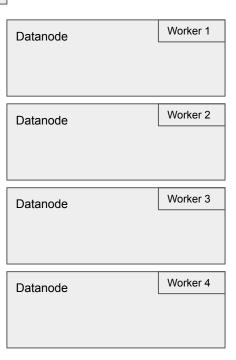


HDFS utilisation et limitation

- ▼ Gros fichier (bloc de 128 Mo)
- Pas de modification des fichiers (append accepté)
- ▼ Optimisé pour la lecture séquentielle de fichier

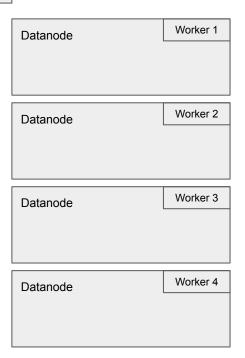
Namenode Master

my_file.txt

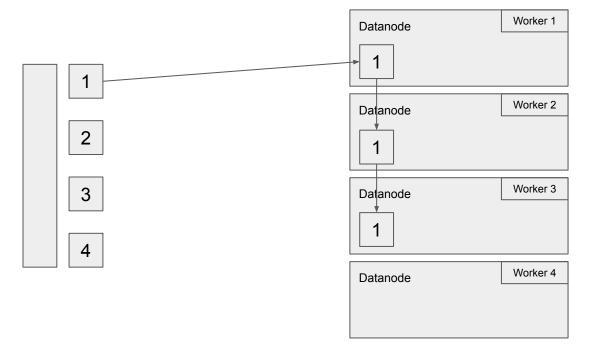


```
Namenode
/users/me/my_file.txt
|-bloc1 ->
|-bloc2 ->
|-bloc3 ->
|-bloc4 ->
```

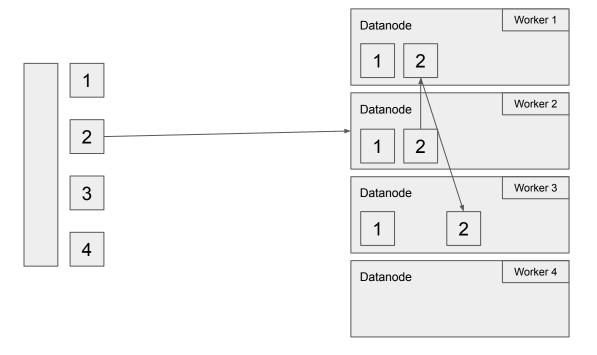




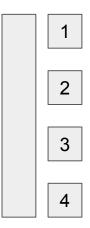
```
Namenode
/users/me/my_file.txt
|-bloc1 -> worker1, worker2, worker3
|-bloc2 ->
|-bloc3 ->
|-bloc4 ->
```

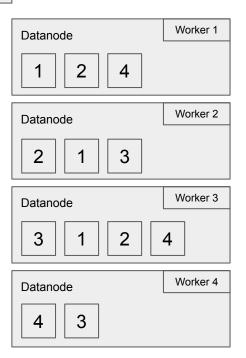


```
Namenode
/users/me/my_file.txt
|-bloc1 -> worker1, worker2, worker3
|-bloc2 -> worker2, worker1, worker3
|-bloc3 ->
|-bloc4 ->
```

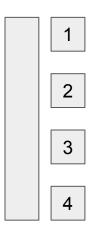


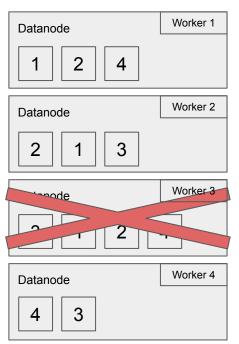
```
Namenode
/users/me/my_file.txt
|-bloc1 -> worker1, worker2, worker3
|-bloc2 -> worker2, worker1, worker3
|-bloc3 -> worker2, worker3, worker4
|-bloc4 -> worker1, worker3, worker4
```











Hive

Hive

- ▼ Vue SQL sur les fichiers du HDFS
- Data Warehouse
- ▼ HiveQL ~= SQL
- ▼ JDBC



Hive

- ▼ Génère du code spark ou mapreduce
- ▼ Donnée Structurée (Parquet, Avro, ...)
- Pas besoin de programmer (SQL)



Hive vs RDBMS

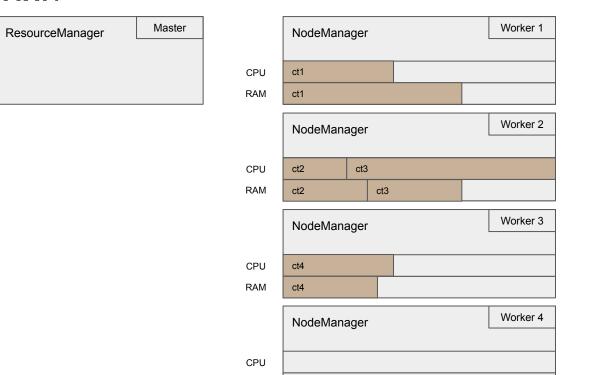
	RDBMS	Hive
Langage de requête	SQL	SQL
Update	Oui	Non
Latence	Faible	Élevé
Scalable	Difficile	Facile
Coût	Élevé	Faible

Yet Another Resource Negotiator

- ▼ Yet Another Resource Negotiator
- Gère la répartition des ressources de calcul
- ▼ Conteneur = CPU + RAM
- Queue pour la répartition équitable

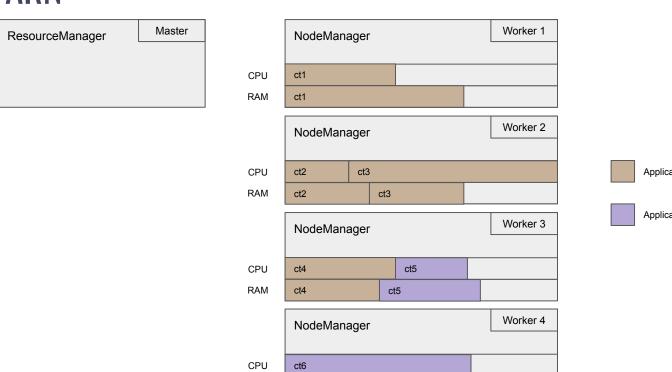


ResourceManager	Master		NodeManager	Worker 1
		CPU		
		RAM		
			NedeMenerer	Worker 2
			NodeManager	
		CPU		
		RAM		
			NodeManager	Worker 3
			Ğ	
		CPU		
		RAM		
			NodeManager	Worker 4
		CPU		
		RΔM		



RAM

Application 1



RAM

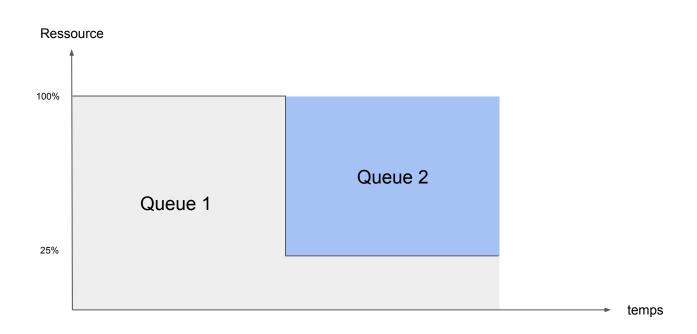
ct6



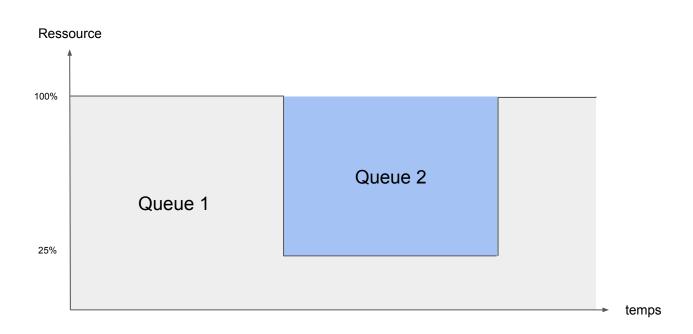
YARN Queue



YARN Queue



YARN Queue



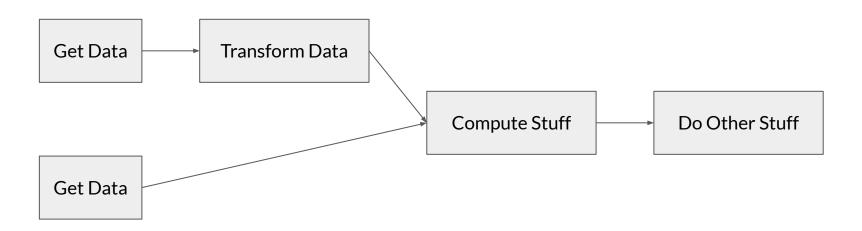
Oozie

Oozie

- Workflow
- Coordinator
 - □ lancement de workflow à heure fixe
 - ▼ lancement suite à événement (arrivé d'un fichier)

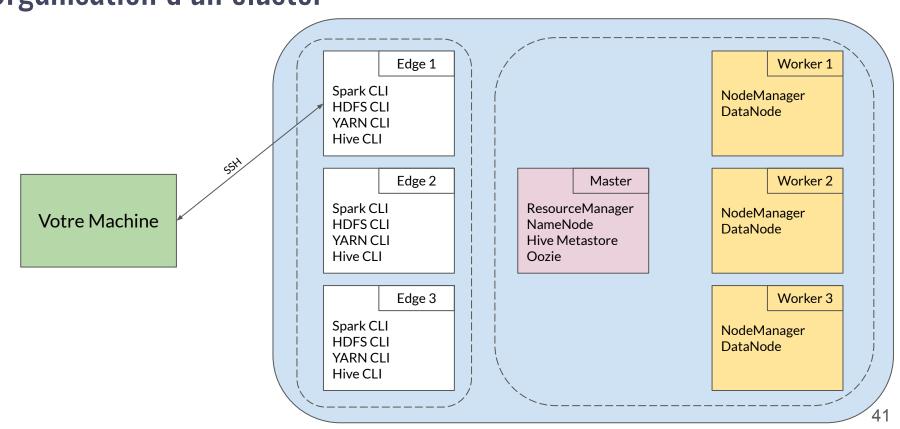


Oozie: Workflow



Organisation d'un Cluster

Organisation d'un cluster



Map Reduce

| Map Reduce

Modèle de programmation inventé en 2004 par Google. Il est utilisé pour paralléliser les calculs en tirant parti d'un système de fichier distribué.

- Map
 - ▽ Projection (SELECT)
 - ▼ Filtre (WHERE)
- Reduce
 - ∇ Aggregation (GROUP BY)
 - ▼ Jointure (JOIN)



Compter des Lego avec map reduce

Combien y a-t-il de brique 8 et 4 dans ce tas de cartes?

- 1. distribuer des lego à chaque node
- 2. chaque node filtre les 8 et 4
- 3. chaque node compte les 8 et 4
- 4. tous les comptes de 8 sont envoyés à un node
- 5. tous les comptes de 4 sont envoyés à un node
- 6. Le "Node 8" ajoute les différents comptes
- 7. Le "Node 4" ajoute les différents comptes